

MEMO INTERNO • AGENTE DE VOZ OUTBOUND

Plano de investimento para escalar de 25 ligações de teste para 50–100/dia — e depois para outras empresas

Baseado no estado real do projeto `agente-voz-outbound` e do `crm-adm` : custos medidos em produção, não estimativa de mercado.

Data 02 ago 2026 • atualizado no mesmo dia **Fonte** logs/custos.log, HANDOFF.md, config.js

Escopo ADM Soluções → multi-cliente

Sobre o tom deste memo: listar bloqueadores não é dizer que o projeto não funciona — o pipeline ponta a ponta **já funciona de verdade**, com 25 ligações reais provando isso. O que vem abaixo é o degrau normal entre "protótipo validado" e "produto rodando volume todo dia". A maioria é resolvível com dinheiro e algumas horas, não redesenho do zero — e um item já foi resolvido enquanto este documento era escrito (ver seção 1).

US\$ 0,02–0,21

custo real por ligação, medido (curta a ~2min)

25

ligações de teste já realizadas

~15–20/dia

teto real hoje (Groq grátis, não o saldo Twilio)

1 Onde estamos hoje

- O pipeline **funciona ponta a ponta**: Twilio → Deepgram (STT) → Groq/Llama (LLM) → Cartesia (TTS) → extração → webhook pro CRM → registro em `ligacoes_agente_voz`.
- Roda **localmente**, exposto por **ngrok** (túnel gratuito). Não é infraestrutura de produção — se o seu PC desligar ou perder internet, o sistema cai no meio de uma ligação.
- **Um único processo Node** atende todas as ligações simultâneas. Já causou três crashes totais em teste (corrigidos na origem, mas a arquitetura continua sem redundância).
- Conta Twilio ainda em **modo trial**: só liga pra números verificados manualmente, com aviso em inglês antes de conectar.
- Groq no **plano gratuito**: teto de 100.000 tokens/dia — um lote de 50–100 ligações reais já estoura isso.
- ☒ **Resolvido hoje**: disparo em lote agora tem **controle de concorrência real** (`scripts/lib/concorrenci.js`, `DISPARO_CONCORRENCIA_MAXIMA` no `.env`, padrão 2). Antes só existia um intervalo fixo de 20s entre o início de cada ligação — como várias duram mais que isso (94s, 155s, 213s já medidos), podiam empilhar sem limite nenhum. Agora consulta o status real e só dispara a próxima quando uma vaga libera de verdade.

2 Custo real por ligação

Do `logs/custos.log`, com uma ligação já com valor de Twilio confirmado:

COMPONENTE	CUSTO
Twilio (voz, saída Brasil)	US\$ 0,0663 / min
Deepgram (STT)	US\$ 0,0077 / min
Cartesia (TTS)	US\$ 0,03 / min
Groq (LLM)	US\$ 0,0003–0,015 / ligação

Ligação curta (~30s): **~US\$ 0,02–0,03**. Ligação de ~2min: **~US\$ 0,13–0,21**.

VOLUME	CUSTO DE API / DIA	CUSTO DE API / MÊS (22 DIAS ÚTEIS)
50 ligações/dia	~US\$ 7–10	~US\$ 155–220

VOLUME	CUSTO DE API / DIA	CUSTO DE API / MÊS (22 DIAS ÚTEIS)
100 ligações/dia	~US\$ 14–20	~US\$ 310–440

Isso é **barato**. O gargalo pra escalar não é custo de API — é infraestrutura, compliance e operação humana. É aí que o investimento real precisa entrar.

Calculadora — projete o custo de API pro seu volume

Os números abaixo usam as taxas reais medidas nesta sessão (Twilio US\$ 0,0663/min, Deepgram US\$ 0,0077/min, Cartesia US\$ 0,03/min, Groq ~US\$ 0,006/ligação médio). Ajuste o volume e a duração média pra ver o impacto direto.

Ligações por dia

75

Duração média por ligação

1,50 min

Dias úteis considerados por mês

22

US\$ 0,16

US\$ 12,15

US\$ 267,30

custo de API / ligação

custo de API / dia

custo de API / mês

Só custo de API (Twilio + Deepgram + Cartesia + Groq). Não inclui servidor, número, ou tempo de operação humana — ver Fase 2 na seção 5. Note que isso é *orçamento* — hoje o Groq no plano grátis trava em ~15–20 ligações/dia bem antes desse valor importar (ver seção 3.2).

3 Bloqueadores para 50–100 ligações/dia — ainda só ADM Soluções

3.1 Infraestrutura — prioridade máxima

BLOQUEIO ATIVO Hoje o sistema não sobrevive a rodar sem a sua máquina ligada. Isso precisa ser resolvido antes de qualquer disparo de lote real.

- Sair da máquina local + ngrok para um servidor real: Railway, Fly.io ou Render (deploy simples, suporta WebSocket, US\$ 5–20/mês) ou uma VPS pequena (Hetzner/DigitalOcean, ~US\$ 6–12/mês). Precisa suportar WebSocket persistente — plataformas serverless como Vercel não servem bem aqui.
- Domínio próprio + HTTPS fixo, no lugar da URL do ngrok que muda a cada reinício.
- Supervisor de processo (pm2 ou systemd) com restart automático em crash e alerta de queda.
- ~~Fila com concorrência controlada~~ —  **resolvido**. Ainda vale lembrar: é controle de *disparo*, não de capacidade do processo — com um único Node atendendo tudo, o teto seguro de concorrência simultânea continua baixo (2–3), porque falta isolamento entre ligações, não porque falte código. Mesma pendência do servidor/supervisor acima.
 - Por que isso é prioridade zero?

3.2 Contas e limites dos provedores

CONTRA-INTUITIVO Os US\$ 20 do Twilio **não são o teto real**. $\text{US\$ } 20 \div \text{US\$ } 0,0663/\text{min} \approx 300 \text{ minutos}$ $\approx$ **230–250 ligações** no padrão de duração já medido (~76s). É a Groq grátis que trava primeiro, em ~15–20 ligações/dia — bem antes do saldo do Twilio acabar.

- **Twilio:** sair do trial (cartão + carga mínima, ~US\$ 20) e verificar o limite de concorrência de chamadas outbound da conta — contas novas costumam ter teto baixo, pode exigir pedido de aumento ao suporte (o controle de concorrência da seção 1 já evita bater nesse teto sozinho, já que nunca dispara mais que o configurado de uma vez).
- **Groq — este é o item que realmente destrava 50–100/dia:** migrar do free tier (100k tokens/dia) para plano pago. Custo por ligação é centavos (ver seção 2), o problema nunca foi preço, foi o teto diário do plano grátis.
- **Deepgram e Cartesia:** confirmar limite de streams simultâneos do plano — streaming concorrente costuma ter teto por plano, não só teto de uso total.
- **Número de origem:** hoje é seu número pessoal verificado manualmente. Comprar um número brasileiro de verdade exige Regulatory Bundle da Twilio com CNPJ da ADM Soluções — pendência que ainda não está formalizada no projeto.
 - Por que o teto da Groq é bloqueio, não só limite teórico?

3.3 Compliance e reputação — o ponto mais esquecido

- **Sinalização de spam:** ligar em volume por um único número, em rajadas curtas, é o padrão que operadoras e apps (TrueCaller etc.) marcam como possível telemarketing — derruba taxa de atendimento com o tempo. Mitigar com throttling por número e rodízio de números.
- **Horário de ligação:** como é prospecção B2B (CNPJ, não CPF), o risco regulatório é menor, mas o agente ainda não trava horário comercial (9h–18h, seg-sex) no código — hoje depende de quem dispara o lote.
- **LGPD:** base legal mais defensável é legítimo interesse, o que exige finalidade documentada, opt-out real e política de retenção. Hoje a transcrição fica salva indefinidamente em `ligacoes_agente_voz`, sem prazo de expurgo.
- **Lista de "não ligar de novo":** não existe ainda — `batchDial.js` / `dialFromCrm.js` podem religar o mesmo lead em outro lote.
 - O que muda por ser B2B (CNPJ) e não B2C (CPF)?

3.4 Qualidade e operação humana

- QA manual (ouvir cada ligação) funciona com 15–25 testes, não com 50–100/dia — precisa de amostragem sistemática + métricas automáticas (taxa de atendimento, de agendamento, de desligamento no meio).
- Follow-up humano dos agendamentos criados pelo agente precisa virar rotina, não checagem ocasional.
- Voz da Cartesia ainda não está 100% natural (nota já deixada no handoff) — vale resolver antes de multiplicar por volume.

4 Escalar para outras empresas — multi-tenant

Hoje o sistema é fixo para uma única empresa: um roteiro (`prompts/roteiro.txt`), um número, um webhook, uma agenda. Vender isso para outras empresas é mudança de arquitetura, não só de volume.

4.1 Arquitetura multi-tenant

- Separar por cliente: roteiro, número de origem, credenciais de calendário, regras de horário e webhook próprios — uma tabela `clientes` configurável, não arquivos `.txt` editados à mão.
- Isolamento de dados entre empresas desde o design — mesmo cuidado de RLS já aplicado no `crm-adm`, mas planejado desde o início aqui.

- Painel de administração para cada cliente configurar o próprio roteiro e ver as próprias ligações.
- Decidir entre subcontas Twilio por cliente (mais vendável como produto) ou cada cliente trazer as próprias chaves (mais simples de construir primeiro).

4.2 Legal e comercial

- Contrato/DPA com cada cliente definindo controlador vs. operador dos dados — vale consulta jurídica especializada em LGPD antes do primeiro cliente externo.
- CNPJ da ADM Soluções formalizado no projeto — necessário tanto para o Regulatory Bundle quanto para emitir nota fiscal caso vire produto cobrado.
- Modelo de cobrança (por ligação, por lead qualificado, ou assinatura com teto) define como o billing técnico precisa medir uso — hoje é só um log local informal.

4.3 Equipe

- 1 pessoa técnica dedicada a manter o pipeline e evoluir roteiro/config por cliente.
- 1 pessoa de onboarding/suporte por cliente novo.
- Conforme a base cresce, QA de ligações entre clientes.

4.4 Infraestrutura em escala

- Migrar de um processo Node para fila de jobs + workers (ex: BullMQ + Redis) para escalar horizontalmente sem reescrever a lógica de conversa.
- Logging estruturado centralizado e alertas automáticos — hoje é `console.log` e um arquivo local.

5 Investimento por fase

FASE	O QUE EXIGE	CUSTO APROXIMADO
1 Sair do trial/local	Controle de concorrência no disparo ☒ feito · Servidor real, domínio, upgrade Twilio, upgrade Groq, supervisor de processo	~US\$ 30–60 setup + US\$ 15–30/mês
2 50–100/dia, 1 empresa	Fila/throttling, lista de não-ligar, janela de horário, QA amostral, CNPJ formalizado, Regulatory Bundle	~US\$ 300–450/mês

FASE	O QUE EXIGE	CUSTO APROXIMADO
		+ operação humana
3 Multi-tenant	Arquitetura multi-cliente, painel admin, DPA jurídico, subcontas Twilio, fila com workers, observabilidade	Depende do nº de clientes

RECOMENDAÇÃO

Resolva a Fase 1 inteira antes de qualquer disparo de lote real — hoje o sistema não sobrevive a rodar sem a sua máquina ligada. A Fase 2 é o piloto de verdade com a ADM Soluções: é ali que se aprende se o roteiro converte em volume, antes de vender para terceiros.

A Fase 3 só faz sentido depois que a Fase 2 provar taxa de agendamento consistente — vender um produto que ainda não converteu bem para você mesmo é o maior risco reputacional de todos.